

SVEUČILIŠNI DIPLOMSKI STUDIJ

Kolegij modeliranja i simulacije - projektna dokumentacija

Odljev mozгова u europskim zemljama

Analiza emigracije visokoobrazovanog kadra
i učinci mjera javne politike

AUTOR

Petar Prenc

DATUM

lipanj 2026.

METODA SIMULACIJE

Sustavna dinamika

System Dynamics

IMPLEMENTACIJA

R / Shiny

15 europskih zemalja · horizont do 2055.

1 Opis sustava i područje primjene

Odljev mozgova (*brain drain*) označava trajnu emigraciju visokoobrazovanih radnika - liječnika, inženjera, informatičara, ekonomista - iz manje razvijenih zemalja prema razvijenijim destinacijama. Za Hrvatsku i slične tranzicijske ekonomije ovaj fenomen nije tek demografski podatak: svaki stručnjak koji ode sa sobom nosi i porezne prihode, inovacijski kapacitet i vrijednost javnih investicija uložениh u njegovo školovanje.

Od ulaska Hrvatske u EU 2013. sloboda kretanja radne snage postala je dvosječni mač - isti zakon koji omogućuje uvoz strane stručnosti domaće stručnjake šalje prema Njemačkoj, Irskoj i skandinavskim zemljama, privučene plaćama i tri do pet puta višim od domaćih. Problematičnost situacije pojačava **samopojačavajuća logika**: što više stručnjaka ode, to su domaće plaće niže, javne usluge lošije i zemlja manje privlačna za preostale - što potiče daljnji odlazak.

Cilj projekta jest kvantificirati tu logiku kroz računalnu simulaciju: koliko dugoročno košta neaktivnost, koliko vrijedi rana intervencija i koje mjere imaju najveći povrat ulaganja. Simulacija pokriva **15 europskih zemalja** - od bugarskog i rumunjskog dna do irskog i njemačkog vrha ljestvice - kako bi se tranzicijskim ekonomijama pokazalo što im predstoji i kamo mogu stići.

Model prati četiri međuovisna elementa sustava: **visokoobrazovanu radnu snagu** (koliko ih je, koliko stigne, koliko ode), **gospodarski rast** (BDP per capita kao mjera životnog standarda), **kvalitetu zdravstvenog sustava** (posebno osjetljivog na odljev liječnika i medicinskih sestara) i **razvoj IT sektora** (koji gubi investicijski zamah kad odlaze programeri i inženjeri).

Model je namijenjen kreatorima politika za procjenu mjera zadržavanja kadrova, ministarstvima za dugoročno planiranje obrazovnih kapaciteta i regionalnim agencijama za optimizaciju korištenja EU fondova.

2 Vrsta simulacije i simulacijski jezik

Zašto sustavna dinamika?

Problem odljeva mozgova ne može se analizirati statičkim alatima. Radi se o sustavu koji se mijenja kroz **desetljeća**, u kojemu odluke i posljedice nisu trenutne, a varijable su međusobno isprepletene povratnim vezama. Primjerice: niže plaće potiču emigraciju, emigracija smanjuje poreznu bazu, manja porezna baza smanjuje javne investicije, manji javni rashodi usporavaju rast plaća - krug se zatvara.

Za ovakve probleme razvijena je metodologija **sustavne dinamike** (*System Dynamics*), pristup koji su 1950-ih na MIT-u razvili Jay Forrester i njegovi suradnici. Osnovna ideja je jednostavna: sustav se opisuje kao skup **zaliha** (npr. broj visokoobrazovanih radnika, razina BDP-a) i **tokova** koji te zalihe pune ili prazne (diplomiranci koji ulaze u tržište rada, emigranti koji ga napuštaju). Povratne veze između varijabli ključne su za razumijevanje zašto sustavi ponekad ne reagiraju onako kako bi kreatori politika očekivali.

Tehnički okvir

Simulacija je implementirana u **programskom jeziku R** i dostupna je kao interaktivna web-aplikacija izrađena u **Shiny** okviru, što znači da je dostupna u pregledniku bez potrebe za instalacijom softvera. Model računa s **kvartalnim korakom** (svaki korak = tri mjeseca) kroz vremenski horizont od **2025. do 2055. godine**.

Radi procjene pouzdanosti rezultata provedena je i **analiza osjetljivosti**: model je pokrenut 80 puta s nasumično variranim pretpostavkama ($\pm 30\%$ od baznih vrijednosti). Ako se zaključci ponavljaju u gotovo svim scenarijima, model je robustan - a rezultati pokazuju upravo to.

Aplikacija korisnicima omogućuje interaktivno postavljanje pitanja: *Što se dogodi ako Hrvatska sutra uvede porezne olakšice? Što ako to učini tek za pet godina? Što ako EU fondovi ostanu na razini 2% BDP-a?*

3 Prikupljeni podaci

Što smo mjerili i odakle

Sve polazne vrijednosti temelje se na **službenim statističkim podacima** iz 2023./2024. godine, prilagođenim kao procjena za baznu godinu simulacije (**2025.**):

- **Eurostat** - BDP per capita, stope emigracije, rashodi za obrazovanje, struktura zaposlenih po sektorima.
- **World Bank World Development Indicators** - relativne razine plaća u odnosu na EU prosjek, udio visokoobrazovanih u radnoj snazi.
- **Državni zavod za statistiku RH (DZS)** - detaljniji podaci za Hrvatsku kao primarno promatranu zemlju.

Za svaku od 15 zemalja prikupljeno je šest ključnih pokazatelja: ukupna populacija, BDP po stanovniku (EUR), udio visokoobrazovanih u radnoj snazi (%), godišnja stopa emigracije (broj emigranata na tisuću stanovnika), razina plaća u usporedbi s EU prosjekom (gdje EU = 1,0) te javni rashodi za obrazovanje kao postotak BDP-a.

Podaci po zemljama

Zemlja	Populacija (mil.)	BDP/st. (EUR)	Visokoobr. (%)	Emigracija (‰/god.)	Razina plaća (EU = 1,0)
Bugarska	6,5	13 200	30	9,8	0,38
Rumunjska	19,2	14 800	28	10,2	0,42
Hrvatska	3,9	18 500	32	8,5	0,50
Mađarska	9,7	19 200	35	7,5	0,52
Grčka	10,7	20 100	41	8,0	0,62
Litva	2,8	22 100	48	6,8	0,62
Portugal	10,3	24 500	38	5,0	0,65
Italija	59,2	35 200	27	4,2	0,90
Njemačka	83,2	48 500	32	1,8	1,15
Irska	5,1	72 000	54	2,5	1,45

Napomena: prikazano je 10 od 15 modeliranih zemalja radi preglednosti; uključene su i Latvija, Estonija, Slovačka, Poljska i Španjolska.

Iz tablice je odmah vidljiva ključna zakonitost: **niže plaće = viša stopa emigracije**. Bugarska (plaće 38 % EU prosjeka) gubi 9,8 stručnjaka na tisuću godišnje; Irska (plaće 45 % iznad prosjeka) gubi samo 2,5. Hrvatska se nalazi otprilike na sredini tog spektra s omjerom plaća od 50 % i stopom od 8,5‰, što u apsolutnim brojevima znači otprilike **6 000–8 000 visokoobrazovanih osoba godišnje**.

4 Konceptualni model

Logika modela - kako sustav funkcionira

Srž modela su dvije "posude" koje se pune i prazne: **broj visokoobrazovanih radnika** i **BDP per capita**. Svake godine u prvu posudu dolaze novi diplomirani, a odlijevaju se emigranti i oni koji odu u mirovinu. Veličina te posude izravno utječe na drugu - više stručnjaka znači veći gospodarski rast, a veći rast dugoročno smanjuje emigraciju jer plaće rastu i zemlja postaje privlačnija.

Zašto sustav sam sebe pojačava - povratne sprege

U sustavu djeluju dvije suprotne sile:

Negativna spirala (R1): Emigracija smanjuje ponudu stručnjaka → plaće padaju ili stagniraju → jaz prema inozemnim plaćama raste → emigracija se povećava. Ovakva petlja se sama pojačava bez vanjske intervencije.

Stabilizacijska petlja (B1): Ako BDP raste dovoljno dugo → plaće se primaknu EU prosjeku → zemlja postaje privlačna za povratnike i imigrantske stručnjake → zaliha obrazovanih raste → BDP raste brže. Ova petlja može preokrenuti negativnu spiralu, ali samo uz početni "guranj" koji politike zadržavanja trebaju osigurati.

Dodatno, veća javna ulaganja u obrazovanje povećavaju broj diplomiraca (petlja R2), a EU fondovi izravno smanjuju emigraciju i ubrzavaju rast (petlja B2).

Pretpostavke modela

Da bi simulacija bila provediva, usvojena su neka pojednostavnjenja: model prati samo visoko-obrazovane radnike; imigracija prema domaćoj zemlji počinje biti relevantna tek kad BDP dosegne razinu od 85 % polazne vrijednosti; uvedene mjere zadržavanja smanjuju emigraciju linearno, s maksimalnim učinkom od 60 % na kraju horizonta; EU fondovi imaju sve manji granični prinos kako zemlja postaje razvijenija.

5 Računalni model

Kako model funkcionira "ispod haube"

Model je napisan u programskom jeziku R i sadrži oko 1450 linija koda. Na ulazu prima demografske i ekonomske podatke svake od 15 zemalja te parametre koje korisnik postavlja (snaga mjera, početak intervencije, razina EU fondova). Na izlazu daje **četiri scenarija simultano** - svaki projekciju za 30 godina unaprijed.


Logika modela određuje da emigracija raste kad je razlika u plaćama veća i kad zemlja nema aktivnih mjera zadržavanja. Broj diplomiraca raste s ulaganjima u obrazovanje. BDP raste brže kad je više obrazovanih radnika, a usporava se s emigracijom. Zdravstveni sustav gubi kvalitetu razmjerno odlasku zdravstvenih radnika, a IT sektor gubi investicijsku dinamiku razmjerno odlasku programera. Sve su te veze modelirane kao **kontinuirani procesi koji se odvijaju istovremeno**, čime se postiže realističnija slika od jednostavnih trend-linija.

Četiri scenarija

Sc.	Naziv	Opis
S0	Bazni scenarij	Nema intervencije; emigracija se odvija prema dosadašnjim trendovima. Pokazuje što se događa ako se ne poduzme ništa.
S1	Politika odmah	Mjere se uvode 2025. Korisnik bira intenzitet: porezne olakšice (blago), subvencije plaća (umjereno), strukturne reforme (jako).
S2	Politika za 5 g.	Iste mjere kao S1, ali odgođene do 2030. Prikazuje trošak oklijevanja.
S3	Optimistički	Sve mjere, maksimalnog intenziteta - teorijski gornji prag mogućeg poboljšanja.

Korisnik može interaktivno podešavati: snagu mjera (od nulte intervencije do punih reformi),

godinu uvođenja politike (2025.–2040.), razinu EU fondova (0–5 % BDP-a), osjetljivost tržišta na razlike u plaćama i vremenski horizont simulacije.



Slika 1: Prikaz cjelokupnog sučelja aplikacije s razvijenom bočnom trakom (lijevo) i glavnim dashboardom (desno). U bočnoj traci vidljivi su kontrolni elementi: odabir primarne države (Hrvatska) i usporedne države (Bugarska), klizač vremenskog horizonta namješten na 2045. (20 godina), te razvijeni padajući izbornik za odabir paketa politike s pet opcija - od nulte intervencije do maksimalnih mjera. U pozadini je vidljiv dashboard s KPI karticama i grafovima koji se ažuriraju prema odabranim parametrima.

NAPREDNI PARAMETRI

Osjetljivost plaće: koliko snažno razlika plaća EU vs. domovina tjera ljude na odlazak.


Edu → BDP elastičnost: za koliko % raste BDP ako poraste udio obrazovanih za 1 postotni bod.

Osjetljivost na razliku plaća



0.5 = slaba - 2.2 = umjerena - 4.0 = visoka

Elastičnost obrazovanje → BDP



0.1 = slab utjecaj - 0.45 = umjeren - 1.0 = jak

EXPORT PODATAKA

↓ Preuzmi CSV (primarna)

↓ Preuzmi CSV (usporedba)

↓ Preuzmi zaključke (.txt)

▶ Pokreni simulaciju

Slika 2: Donji dio bočne trake s naprednim parametrima simulacije. Klizač *Osjetljivost na razliku plaća* (zadana vrijednost 2,2) kontrolira koliko snažno jaz između domaćih i inozemnih plaća tjera stručnjake na odlazak - raspon od 0,5 (slab utjecaj) do 4,0 (visok utjecaj) omogućuje testiranje od pesimističnih do optimističnih pretpostavki o mobilnosti radne snage. Klizač *Elastičnost obrazovanje → BDP* (zadana vrijednost 0,45) određuje koliko posto raste BDP per capita za svaki postotni bod porasta udjela visokoobrazovanih u radnoj snazi. Ispod su gumbi za izvoz rezultata u CSV formatu te gumb za pokretanje simulacije.


6 Rezultati, tumačenje i preporuke

Što se dogodi bez intervencije - bazni scenarij

Za Hrvatsku, model projicira sljedeće do 2055. ako se ne poduzme ništa:

- Kumulativni gubitak od **22–25 %** visokoobrazovane radne snage - u apsolutnim brojevima, oko 180 000–220 000 stručnjaka koji su trajno napustili zemlju.
- Usporavanje rasta BDP-a per capita na **1,4–1,8 % godišnje**, nasuprot potencijalnih 3,2 % koji bi bili dostižni da emigracija nije toliko intenzivna.
- Vidljivo pogoršanje u zdravstvenom sustavu - indeks kvalitete pada s 0,70 na ispod 0,55 do 2045., što odgovara dužim čekanjima, zatvaranju odjela i odlasku liječnika specijalista.
- Zaostajanje u digitalizaciji jer IT investicije stagniraju bez domaćih stručnjaka.

Rumunjska i Bugarska, s višim stopama emigracije i nižim plaćama, u istom scenariju gube do **28 %** visokoobrazovanih - apsolutno najviše u uzorku.



Slika 3: Glavni dashboard aplikacije - simulacija za Hrvatsku, horizont 2025.–2045. Pet KPI kartica u gornjem redu prikazuju ključne ishode baznog scenarija: BDP per capita raste na €53.054 (+191,5% od 2025.), udio visokoobrazovanih dostiže 49,5% radne snage, vršna godišnja emigracija iznosi 14,8 tisuća osoba (vrhunac 2045.), kumulativni gubitak kadra 235 tisuća osoba, a kvaliteta zdravstvenog sustava pada za 13,8%. Srednji grafikon prikazuje projekciju BDP-a per capita za sva četiri scenarija od 2025. do 2045. - scenariji s politikama postupno se odvajaju od baznog scenarija, s optimističnim dosezanjem €60.000. Donji lijevi grafikon pokazuje rast udjela visokoobrazovanih u radnoj snazi s 30% na oko 50%, s vidljivom razlikom između scenarija tek u drugoj polovici horizonta. Donji desni grafikon prikazuje godišnji saldo migracije (stupci za imigraciju i emigraciju, linija za neto vrijednost) - neto migracija ostaje negativna kroz cijelo promatrano razdoblje, ali se negativni saldo postupno smanjuje zahvaljujući rastu imigracije.

Što donosi pravovremena intervencija

Uvođenje mjera umjerenog intenziteta odmah 2025. (scenarij S1) donosi:


- Smanjenje godišnje emigracije za **35–40 %** u roku od pet godina od uvođenja mjera.
- BDP per capita u 2055. viši za **3 200–4 800 EUR** u odnosu na scenarij bez intervencije.
- Stabilizaciju udjela visokoobrazovanih iznad 35 % radne snage - dovoljan prag za održivu inovacijsku ekonomiju.
- Oporavak zdravstvenog sustava prema polaznim razinama do 2050.

Trošak oklijevanja

Odgoda uvođenja istih mjera za samo pet godina (scenarij S2 nasuprot S1) donosi:

- **18 000–25 000 stručnjaka više** koji su u međuvremenu trajno napustili zemlju.
- Razliku u BDP-u od **1 500–2 200 EUR po stanovniku** na kraju horizonta - trajan i nenadoknativ jaz.
- Nepovratne gubitke u zdravstvenom sustavu koji se ne mogu kompenzirati ni naknadnom maksimalnom intervencijom.


Ključni zaključak: brzina je važnija od intenziteta mjera. Umjerena politika uvedena danas daje bolje rezultate od snažne politike uvedene za pet godina.



Slika 4: Kartica *Analiza scenarija* - kvantifikacija dobiti od pojedinih paketa politike u usporedbi s baznim scenarijem bez intervencije, Hrvatska 2025.–2045. Gornji grafikon prikazuje razliku BDP-a per capita u eurima između svakog scenarija i baznog (S0): optimistički scenarij (S3, narančasta) do 2045. donosi €8.000 više per capita od scenarija bez mjera, dok scenariji S1 i S2 jedva odskoču na skali - učinak umjerenih mjera akumulira se sporije. Donji lijevi grafikon uspoređuje kumulativnu emigraciju: bazni scenarij (crvena) dostiže oko 250 tisuća, dok politika odmah (S1, plava) i optimistički scenarij (S3, narančasta) zadržavaju kumulativ ispod 200 tisuća - razlika od 50.000 do 60.000 stručnjaka koji ostaju u zemlji. Politika za 5 godina (S2, zelena) rezultira gotovo istim kumulativom kao bazni, što potvrđuje da odgoda u potpunosti poništava dobrobit mjera. Donji desni grafikon prikazuje IT investicijski indeks: svi scenariji rastu, ali S1 i S3 zadržavaju neznatno viši indeks, što odražava sposobnost zadržavanja IT kadrova kao ključnog pokretača digitalne ekonomije.

Usporedba zemalja - Hrvatska i Bugarska

Usporedba s Bugarskom posebno je ilustrativna jer je riječ o zemlji s gotovo identičnim polaznim udjelom visokoobrazovanih, ali nižim BDP-om i višom stopom emigracije, što pojačava spiralu odljeva.




Slika 5: Kartica *Usporedba zemalja* - Hrvatska (HR) nasuprot Bugarskoj (BG), horizont 2025.–2045. Gornji lijevi grafikon prikazuje BDP per capita u baznom i optimističnom scenariju za obje zemlje: Hrvatska polazi s €18.200 i u optimističnom scenariju dostiže oko €55.000, dok Bugarska polazi s €13.500 i usprkos sličnom rastu ostaje ispod €35.000 zbog manje polazne osnove. Gornji desni grafikon pokazuje udio visokoobrazovanih u radnoj snazi - obje zemlje kreću s oko 30%, ali Hrvatska u optimističnom scenariju dostiže 50%, a Bugarska oko 46%, što odražava Bugarsku slabiju sposobnost zadržavanja diplomiranih kadrova zbog jačeg pritiska emigracije. Srednji grafikon kumulativne emigracije (bazni scenarij) najdramatičniji je: Bugarska do 2045. gubi oko 600 tisuća visokoobrazovanih (plava površina), Hrvatska oko 200 tisuća (crvena površina) - omjer 3:1 koji se može objasniti višom bugarskom stopom emigracije (20,5‰ prema 18,5‰ za Hrvatsku) i tripud manjom polaznom bazom plaća. Donja tablica s podacima Eurostata 2023. potvrđuje razlike: Bugarska ima razinu plaća samo 42% EU prosjeka nasuprot 58% za Hrvatsku, a njena stopa emigracije viša je za 2‰.

Pouzdanost rezultata - analiza osjetljivosti

Analiza osjetljivosti (80 simulacijskih ponavljanja s nasumičnom varijacijom svih pretpostavki za $\pm 30\%$) potvrđuje robusnost nalaza: razlika između scenarija s intervencijom i bez nje konzistentna je u **96 %** svih ponavljanja. Medijalna projekcija BDP-a per capita za Hrvatsku 2055. iznosi 31 500 EUR (scenarij S1) nasuprot 26 800 EUR (scenarij S0).

Irska služi kao referentni primjer: nekadašnja zemlja visoke emigracije danas je neto uvoznica visokoobrazovane radne snage, zahvaljujući kombinaciji niskog poreza na dobit, masovnih FDI i EU kohezijskih fondova 1990-ih. Simulacija u optimističkom scenariju (S3) za Hrvatsku ponavlja sličan obrazac - preokret je moguć unutar 10–15 godina uz odlučnu i konzistentnu politiku.



Slika 6: Kartica *Metodologija* - lijevo specifikacija Stock & Flow modela, desno Monte Carlo analiza osjetljivosti i usporedba polaznih BDP-a za sve modelirane EU zemlje. Gornji desni histogram prikazuje raspodjelu finalnog BDP-a per capita Hrvatske u 2045. dobivenu iz 80 simulacijskih ponavljanja s $\pm 30\%$ perturbacijom parametara: medijalna vrijednost iznosi €54.076, interkvartilni raspon €46.114–€61.493. Relativno širok raspon odražava visoku osjetljivost dugoročnih projekcija na pretpostavke o mobilnosti radne snage i tempu rasta, ali istovremeno potvrđuje da pozitivni učinak mjera ostaje konzistentan u svim scenarijima. Donji horizontalni stupčasti dijagram prikazuje polazne vrijednosti BDP-a per capita (Eurostat 2023.) za svih 15 modeliranih zemalja, od Bugarske (€13.500) do Irske (€54.500) - Hrvatska (tamno plava) smještena je u donju trećinu ljestvice, između Grčke i Latvije, što dočarava razvojni jaz koji simulacija nastoji kvantificirati.

Preporuke

Na temelju rezultata simulacije, sljedeće mjere preporučuju se po prioritetu:

- Odmah pokrenuti paket fiskalnih mjera (2025.–2027.):** sniženje poreza i doprinosa za visokoobrazovane, subvencionirane stipendije uz obvezu ostanka 3–5 godina, transparentni karijerni putovi u javnom sektoru. Svaka godina odgode nosi trajan i nenadoknativ demografski i ekonomski trošak.
- Sektorski ciljani programi za zdravstvo i IT.** Ova dva sektora nerazmjerno gube kadrove i nerazmjerno utječu na ukupnu kvalitetu javnih usluga i ekonomski rast. Konkurentne plaće u tim segmentima trebaju biti prioritet neovisno o širim fiskalnim ograničenjima.
- Maksimizirati EU fondove u prvom desetljeću.** Model pokazuje da EU fondovi imaju sve manji granični učinak kako zemlja postaje razvijenija - novac je najvredniji sada. Sredstva treba usmjeriti na projekte koji izravno povećavaju produktivnost i domaće plaće, a ne samo na infrastrukturu.
- Programi povratka dijaspore.** Imigracija i povratak stručnjaka postaju značajni tek kad BDP dostigne oko 85 % polazne razine - financijski stimulansi i administrativne olakšice za povratnike mogu ubrzati dostizanje tog praga.
- Godišnji monitoring ključnih pokazatelja.** Sustavi s povratnim spregama reagiraju na promjene politike s kašnjenjem od 3–7 godina. Bez sustavnog praćenja stope emigracije, udjela visokoobrazovanih i BDP-a/st., donositelji odluka ne mogu pravovremeno prilagoditi mjere.

Mjera	Hitnost	Učinak na zadržavanje	Trošak
Fiskalne olakšice za visokoobrazovane	Visoka	Visok	Umjeren
Sektorski programi (zdravstvo, IT)	Visoka	Visok	Visok
EU fondovi - prioritizacija	Visoka	Umjeren	Nizak
Programi povratka dijaspora	Umjerena	Umjeren	Nizak
Godišnji monitoring	Umjerena	Strateški	Nizak

Ograničenja

Model je namjerno pojednostavljen: ne razlikuje podskupine stručnjaka (npr. liječnik vs. programer), ne modelira eksplicitno razinu korupcije ili vladavine prava, ne uzima u obzir moguće geopolitičke šokove. Usprkos tome, zaključci su konzistentni u gotovo svim ponavljanjima osjetljivostne analize - kvalitativna poruka modela ne ovisi o pretpostavkama koje su nesigurne.

Zaključak

Simulacija nedvosmisleno pokazuje da europske tranzicijske ekonomije - s Hrvatskom kao tipičnim primjerom - bez aktivnih mjera nastavljaju prema samopojačavajućoj spirali emigracije i zaostajanja. Gubitak četvrtine visokoobrazovane radne snage do 2055. nije pesimistična projekcija, već rezultat koji model u baznom scenariju konzistentno reproducira.

Dobra vijest jest da je preokret moguć i da Hrvatska ima sve alate i pristup resursima (EU fondovi, fiskalni prostor, dijaspora) koji su Irskoj omogućili sličan zaokret u roku od jednog desetljeća. Ključna razlika između scenarija koji dovode do preokreta i onih koji ne dovode nije u snazi mjera, već u **brzini odluke**.

Popis literature

- [1] Eurostat (2023). *Migration and migrant population statistics*. Publications Office of the EU.
- [2] World Bank (2023). *World Development Indicators 2023*. Washington, DC.
- [3] Državni zavod za statistiku (2023). *Statističke informacije 2023*. Zagreb: DZS.
- [4] Sterman, J. D. (2000). *Business Dynamics: Systems Thinking and Modeling for a Complex World*. Irwin/McGraw-Hill.
- [5] Docquier, F., & Rapoport, H. (2012). Globalization, brain drain, and development. *Journal of Economic Literature*, 50(3), 681–730.
- [6] Clemens, M. A. (2011). Economics and emigration: Trillion-dollar bills on the sidewalk? *Journal of Economic Perspectives*, 25(3), 83–106.
- [7] Lucas, R. E. (1988). On the mechanics of economic development. *Journal of Monetary Economics*, 22(1), 3–42.
- [8] Soetaert, K., Petzoldt, T., & Setzer, R. W. (2010). Solving differential equations in R: Package deSolve. *Journal of Statistical Software*, 33(9), 1–25.
- [9] R Core Team (2024). *R: A Language and Environment for Statistical Computing*. R Foundation. <https://www.R-project.org/>